

MATCP - RESUMOS

1º ANO | 2º SEMESTRE

## PROBABILIDADES

- Fenômeno aleatório → fenômeno sujeito à influência do acaso, fora do alcance do observador
- Invisibilidade e regularidade estatística
- Experiência aleatória
- Pode repetir-se um grande nº de vezes nas mesmas condições (ou condições semelhantes)
  - Dá um resultado de entre um conjunto de resultados possíveis
  - Cada resultado é imprevisível mas é possível considerar estabilidade de frequência de ocorrência
- Espaço de resultados ou espaço amostra ( $\Omega$ ) → Conjunto de todos os resultados possíveis associados a uma experiência aleatória
- Acontecimento aleatório → qualquer subconjunto do espaço de resultados

## ÁLGEBRA DOS ACONTECIMENTOS

- Dado  $\Omega$  o espaço de resultados associado a uma experiência aleatória.
- Diz-se que  $A \subset \Omega$  se realiza se o resultado da experiência,  $w$ , é um elemento de  $A$ , isto é,  $w \in A$
- $A \subset B$  -  $A$  é um subacontecimento de  $B$  se e só se a realização de  $A$  implica a realização de  $B$
- $\bar{A}$  - acontecimento complementar (ou contrário) de  $A$  é o conjunto de todos os elementos de  $\Omega$  que não estão em  $A$
- $A \cup B$  - união de  $A$  com  $B$  é o acontecimento que consiste na realização de um dos acontecimentos  $A$  ou  $B$ .
- $A \cap B$  ou  $A \cap B$  - "produto" ou interseção é o acontecimento que se realiza apenas quando ambos os acontecimentos de realizam
- $A \setminus B = A \cap \bar{B}$  - diferença dos acontecimentos  $A \subset B$  é o acontecimento que se realiza se e só se  $A$  se realiza sem que  $B$  se realize
- $\emptyset$  - acontecimento impossível
- $\Omega$  - acontecimento certo
- Mutuamente exclusivos - Os acontecimentos, se e só se a realização de um implica a não realização do outro
- $$A \cap B = \emptyset$$

## PROPRIEDADES DAS OPERAÇÕES SOBRE A CONTEÚDOS

### Comutatividade

$$A \cup B = B \cup A$$

$$A \cap B = B \cap A$$

### Associatividade

$$(A \cup B) \cup C = A \cup (B \cup C)$$

$$(A \cap B) \cap C = A \cap (B \cap C)$$

### Distributividade

$$(A \cup B) \cap C = (A \cap C) \cup (B \cap C)$$

$$(A \cap B) \cup C = (A \cup C) \cap (B \cup C)$$

### Leis de De Morgan

$$\overline{A \cup B} = \overline{A} \cap \overline{B}$$

$$\overline{A \cap B} = \overline{A} \cup \overline{B}$$

## PROBABILIDADE DE UM ACONECIMENTO

$$P(A) = \frac{\text{n. de casos favoráveis de } A}{\text{n. total de casos possíveis}}$$

} Definição clássica  
(Todos os casos são igualmente possíveis)

$$f_n(A) = \frac{n(A)}{n} \rightarrow \text{n. de vezes que se verificou o acontecimento } A$$

$$\xrightarrow{\text{Definição frequencista}} \text{n. de repetições de uma experiência aleatória}$$

NOTA  
Para  $n$  grande  $f_n(A) \approx P(A)$

## AXIONÁTICA DAS PROBABILIDADES

Probabilidade ( $P$ ) é uma aplicação que a cada acontecimento de  $\Omega$  faz corresponder um número real.

$$\boxed{P: \Omega \rightarrow \mathbb{R}}$$
$$A \mapsto P(A)$$

E que satisfaça os seguintes axiomas:

$$A_1) P(A) \geq 0, \forall A \subset \Omega$$

$$A_2) P(\Omega) = 1$$

$$A_3) P(A \cup B) = P(A) + P(B) \quad \text{e} \quad A \cap B = \emptyset$$

## LEIS DAS PROBABILIDADES

- 1  $P(\bar{A}) = 1 - P(A)$
- 2  $P(\emptyset) = 0$
- 3  $A \subset B \implies P(A) \leq P(B)$
- 4  $P(A) \leq 1$

5  $P(A|B) = P(A \cap \bar{B}) = P(A) - P(A \cap B)$

6  $P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i) \text{ se } A_i \cap A_j = \emptyset, i \neq j$

7  $P(A \cup B) = P(A) + P(B) - P(A \cap B)$

8  $P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i) - P(A_1 \cap A_2) - P(A_1 \cap A_3) - \dots - P(A_{n-1} \cap A_n) + P(A_1 \cap A_2 \cap A_3) + \dots + P(A_{n-2} \cap A_{n-1} \cap A_n) + \dots + (-1)^{n-1} P(A_1 \cap A_2 \cap \dots \cap A_n)$

Probabilidade condicionada

Probabilidade condicionada de  $A$  dado  $B$  ou probabilidade de  $A \geq B$  (PCGSO)

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

Teorema

Se  $P(A) > 0 \wedge P(B) > 0$  ent<sup>a</sup>:  
 $P(A \cap B) = P(A) \times P(B|A) = P(B) \times P(A|B)$

INDEPENDÊNCIA

Dois acontecimentos dizem-se independentes se e s<sup>o</sup> se:  
 $P(A \cap B) = P(A) \times P(B)$

TEOREMA DA PROBABILIDADE TOTAL

Segundo  $A_1, A_2, \dots, A_n$  acontecimentos que definem uma partição de  $\Omega$ , isto é,

$A_1 \cup A_2 \cup \dots \cup A_n = \Omega \wedge A_i \cap A_j = \emptyset, \forall i \neq j$ .

$A_1 \cup A_2 \cup \dots \cup A_n$  e  $A_i \cap A_j = \emptyset, \forall i \neq j$ .

Se  $P(A_i) > 0$  ent<sup>a</sup> para qualquer acontecimento  $B \subset \Omega$  tem-se:

$$P(B) = \sum_{i=1}^n P(B|A_i) P(A_i)$$

## Teorema de Bayes

Sejam  $A_1, A_2, \dots, A_n$  acontecimentos que definem um particípio de  $\Omega$  tais que  $P(A_i) > 0$  e seja  $B$  um outro acontecimento de  $\Omega$ .  
Então para  $k = 1, \dots, n$ , temos:

$$P(A_k | B) = \frac{P(A_k) P(B | A_k)}{\sum_{i=1}^n P(A_i) P(B | A_i)}$$

## Variável aleatória

(v.a.) é uma função de domínio  $\Omega$  e contradomínio contidos em  $\mathbb{R}$ , cujo valor é determinado pelo resultado do experimento aleatório.

$$X: \Omega \rightarrow \mathbb{R}$$

$$\omega \mapsto X(\omega) = x$$

Aos valores de uma variável aleatória associamos uma probabilidade

## Função distribuição acumulativa (ou função distribuição)

Representa-se por  $F$  ou  $F_x$ :

$$F: \mathbb{R} \rightarrow [0, 1]$$
$$x \mapsto F(x) = P[X \leq x]$$

## Propriedades da função distribuição

- $0 \leq F(x) \leq 1$
- $F(-\infty) = 0$  e  $F(+\infty) = 1$
- Se  $x_1 < x_2$  então  $F(x_1) < F(x_2)$
- $P(X = a) = F(a) - F(a^-)$
- $P(X < x) = P(X \leq x) - P(X = x)$
- $P(X \geq x) = 1 - P(X < x)$
- $P(a < X \leq b) = P(X \leq b) - P(X \leq a)$
- $P(a < X < b) = P(X < b) - P(X \leq a)$
- $P(a \leq X \leq b) = P(X \leq b) - P(X < a)$
- $P(a \leq X < b) = P(X < b) - P(X < a)$

Tipos de variáveis aleatórias

Discreta - Se o conjunto de valores que pode assumir for universal ou infinitamente universal

Contínua - Se o conjunto de valores que pode assumir não for universal (assume qualquer valor real)

## DISTRIBUIÇÕES DISCRETAS

Função de probabilidade

Seja  $X$  uma v.a. discreta podendo assumir os valores  $x_1, x_2, \dots, x_n$ . Chama-se função massa de probabilidade ou função de probabilidade da v.a.  $X$  à aplicação que a cada valor  $x_i$  faz corresponder  $f(x_i) = P(X=x_i)$ .

Propriedades

$$1) f(x_i) \geq 0, \forall x_i$$

$$2) \sum_{i=1}^n f(x_i) = 1$$

$x_i$	$x_1$	$x_2$	$\dots$	$\dots$	$x_n$
$f(x_i) = P(X=x_i)$	$f(x_1)$	$f(x_2)$	$\dots$	$\dots$	$f(x_n)$

$$F(z) = P(X \leq z) = \sum_{x_k \leq z} P(X=x_k) = \sum_{x_k \leq z} f(x_k)$$

Parâmetros de uma distribuição discreta

Valor médio

Valor médio ou esperança matemática ou valor esperado ou média

$$E(X) = \mu_X = \mu = \sum_{i=1}^n x_i p_i = \sum_{i=1}^n x_i f(x_i)$$

### Propriedades do valor médio

$$1) E(k) = k \quad (k \text{ constante})$$

$$2) E(kx) = kE(x)$$

$$3) E\left(\sum_{i=1}^n x_i\right) = \sum_{i=1}^n E(x_i)$$

### Variância

$$\begin{aligned} \text{Var}(x) &= V(x) = \sigma_x^2 = \sigma^2 = E[(x - \mu)^2] \\ &= \sum_{i=1}^n (x_i - \mu)^2 f(x_i) \\ &= E(x^2) - E(x)^2 \end{aligned}$$

### Desvio-padrão

$$\sigma = \sqrt{V(x)}$$

### Propriedades da variância

$$1) V(x) \geq 0$$

$$2) V(k) = 0$$

$$3) V(kx) = k^2 V(x)$$

$$4) V\left(\sum_{i=1}^n x_i\right) = \sum_{i=1}^n V(x_i) \text{ se } x_i \text{ v.a's independentes}$$

## DISTRIBUIÇÃO DE BERNoulli

### Prova de Bernoulli

Experiência aleatória que só pode ter dois resultados → **Sucesso** (caso ocorre um acontecimento) e **insucesso** (caso não ocorre)

É a distribuição associada à contagem do número de sucessos que ocorrem num único prova de Bernoulli. Representa-se por:

$$X \sim Be(p)$$

$p \rightarrow$  probabilidade de ocorrer "Sucesso"  
 $q = 1 - p \rightarrow$  probabilidade de ocorrer "insucesso"

### função de probabilidade

$$f(x) = \begin{cases} 1 - p & , x = 0 \\ p & , x = 1 \end{cases}$$

### valor médio

$$\mu = E(X) = \sum_{i=1}^2 x_i p_i = 0(1-p) + 1 \times p = p$$

### Variância

$$\sigma^2 = V(X) = \sum_{i=1}^2 x_i^2 p_i - \mu^2 = p - p^2 = p(1-p) = pq$$

## DISTRIBUIÇÃO BINOMIAL

Seja  $X$  uma v.a. que conta o  $n$  de sucessos numa sequência de  $n$  provas

Repetidas onde:

1) As provas são todos de Bernoulli

2) As provas são independentes (o resultado obtido na atele os restantes)


3) A probabilidade de sucesso é igual em todos as provas

Função de probabilidade (dist. Binomial)

$$f(x) = \begin{cases} \binom{n}{x} p^x q^{n-x}, & x = 0, 1, 2, \dots, n \\ 0 & , x \notin \{0, 1, 2, \dots, n\} \end{cases}$$

Função de distribuição

$$F(x) = P(X \leq x) = \sum_{k=0}^x \binom{n}{k} p^k q^{n-k}, \quad x = 0, 1, 2, \dots, n$$



Valor médio

$$\mu = E(X) = E\left(\sum_{i=1}^n x_i\right) = \sum_{i=1}^n E(x_i) = np$$

Variância

$$\sigma^2 = V(X) = V\left(\sum_{i=1}^n x_i\right) = \sum_{i=1}^n V(x_i) = np(1-p) = npq$$

## DISTRIBUIÇÃO DE POISSON

### Processo de Poisson

- Refere-se ao nº de acontecimentos que ocorrem num intervalo (tempo/espaço)  
e que tem as seguintes propriedades:
- 1) A probabilidade de que ocorram x acontecimentos num intervalo t  
de tempo depende apenas do  $\lambda \equiv k$  e da duração do intervalo t  
(não depende do índice da contagem)  
(não depende dos intervalos de tempo distintos)
  - 2) O nº de eventos que ocorrem em intervalos de tempo distintos  
são independentes (não tem memória)
  - 3) A probabilidade de ocorrer um evento num intervalo muito  
pequeno é proporcional ao comprimento do intervalo
  - 4) A probabilidade de ocorrer mais do que um evento num  
intervalo muito pequeno é zero

### Distribuição de Poisson

Usada para modelar a ocorrência de acontecimentos raros (probabilidade característica baixa)  
que ocorrem com uma taxa média de ocorrerem  $\lambda$  em intervalos de tempo  
ou dentro de um espaço limitado

X tem distribuição de Poisson de parâmetro  $\lambda > 0$   
 $X \sim P_0(\lambda)$

#### Função Probabilística

$$f(x) = P(X=x) = \begin{cases} \frac{e^{-\lambda} \lambda^x}{x!}, & x \in \{0, 1, \dots\} \\ 0, & x \notin \{0, 1, \dots\} \end{cases}$$

#### Função Distribuição

$$F(x) = P(X \leq x) = e^{-\lambda} \sum_{k=0}^x \frac{\lambda^k}{k!}, \quad x \in \{0, 1, \dots\}, \lambda > 0$$

#### Valor médio e Variância

Se  $X \sim P_0(\lambda)$  então:

$$\mu = E(X) = \lambda$$

$$\sigma^2 = V(X) = \lambda$$

### Teorema

Se  $X$  representa o nro de acontecimentos que ocorre num intervalo de amplitude unitária  $I$  e  $X \sim P_0(\lambda)$  é a v.a. representante o nro de eventos que ocorrem num intervalo de amplitude  $d\lambda$

$$Y \sim P_0(d\lambda)$$

### Teorema

Quando  $n \rightarrow \infty$  e  $p \rightarrow 0$  mantendo-se constante o produto  $np$  tende a  $\infty$

$$X \sim Bi(n, p) \Rightarrow X \sim P(\lambda) \text{ com } \lambda = np$$

### Nota

A distribuição de Poisson surge como o limite da distribuição de Binomial quando  $n \rightarrow \infty$  e  $p \rightarrow 0$

Regras Práticas

A dist. de Poisson fornece uma boa aproximação da distribuição binomial

quando  $n \geq 0$  e  $p \leq 0,05$

Ex:  $X \sim Bi(100; 0,05) \approx X \sim P_0(100 \times 0,05)$

$$P(X=4) \approx P(X=4) \quad \left\{ \begin{array}{l} \lambda=5 \\ x=4 \end{array} \right. \quad 0,1955$$

## DISTRIBUIÇÕES CONTÍNUAS

### VARIÁVEIS ALEATÓRIAS CONTÍNUAS

- Uma v.a. contínua pode assumir qualquer valor dentro de um intervalo de ~~mesmo~~ zeros
- Não é possível listar, individualmente, todos os valores de uma v.a. contínua
- → O quadro de distribuição usado nas distribuições discrete é inadequado
- Assoaram-se probabilidades = intervalos e não a pontos

### Função densidade de probabilidade

Seja  $X$  uma v.a. contínua.

A função densidade de probabilidade (f.d.p) ou função densidade de  $X$  é


A função  $f$  tal que:

$$P(a \leq X \leq b) = \int_a^b f(x) dx$$

e que verifica as seguintes propriedades

$$1) f(x) \geq 0, \forall x \in \mathbb{R}$$

$$2) \int_{-\infty}^{+\infty} f(x) dx = 1$$



### Função distribuição

Seja  $X$  uma v.a. contínua com f.d.p  $f$ .

A função distribuição  $X$  é dada por

$$F(x) = P(X \leq x) = \int_{-\infty}^x f(t) dt, -\infty < x < +\infty$$

## Valor médio e variância

$X$  é uma v.a. contínua com função densidade de probabilidade  $f$

$$\mu = E(X) = \int_{-\infty}^{+\infty} x f(x) dx$$

$$\sigma^2 = V(X) = \int_{-\infty}^{+\infty} (x - \mu)^2 f(x) dx = E(X^2) - E(X)^2$$

## DISTRIBUIÇÃO NORMAL

Muitas vezes usada para representar quantidades que resultam de um grande N.º de quantidades aleatórias (Teorema do Límite Central)  
Usada também para representar características de populações relacionadas com medidas ou com os respectivos erros  
ou imprecisões (modelizando estocasticamente de muitos fenômenos naturais)

### Definição


A v.a. contínua  $X$  tem distribuição normal ou distribuição de Gauss com parâmetros  $\mu$  e  $\sigma^2$  se representar-se por:

$$X \sim N(\mu, \sigma^2)$$


Se  $x$  sua função densidade de probabilidade é:

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}, x \in \mathbb{R}$$


f. densidade da  $N(0,1)$



f. densidade da  $N(0,2)$



f. densidade da  $N(2,2)$



Gráficos da função densidade normal para alguns valores de  $\mu$  e  $\sigma$ .

Propriedades da curva da densidade de uma v.a com distribuição normal

→ Domínio  $\mathbb{R}$

→ Tem a forma de sino e um único máximo em  $x = \mu$


→ É simétrica relativamente a um eixo vertical em  $x = \mu$  (média), a mediana também ocorre em  $x = \mu$

→ Tem dois pontos de inflexão em  $x = \mu - \sigma$  e  $x = \mu + \sigma$

→ O eixo das  $x$  é uma assíntota


## Função Densidade de Probabilidade

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, x \in \mathbb{R}$$



## Função de Distribuição

$$F(x) = P(X \leq x) = \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^x e^{-\frac{(t-\mu)^2}{2\sigma^2}} dt$$



## Distribuição normal reduzida

A v.a.  $Z$  tem distribuição normal reduzida se  $\mu = 0$  e  $\sigma = 1$

$$Z \sim N(0,1)$$

A função densidade de probabilidade é:

$$\varphi(z) = \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}}$$

e a função distribuição

$$\Phi(z) = P(Z \leq z) = \int_{-\infty}^z \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt$$

## Teorema

Se  $X \sim N(\mu, \sigma^2)$  e  $Y = a + bX$  então:

$$Y \sim N(a + b\mu, b^2\sigma^2)$$

Corolário

Se  $X \sim N(\mu, \sigma^2)$  então a v.a  $Z = \frac{X-\mu}{\sigma}$  tem distribuição normal reduzida, isto é,

$$Z = \frac{X-\mu}{\sigma} \sim N(0,1)$$

## Cálculo de probabilidades

$$X \sim N(\mu, \sigma^2) \Rightarrow Z = \frac{X-\mu}{\sigma} \sim N(0, 1)$$

- $F(a) = P(X \leq a) = P(Z \leq \frac{a-\mu}{\sigma}) = \Phi\left(\frac{a-\mu}{\sigma}\right)$
- $P(X > b) = 1 - P(X \leq b) = 1 - P\left(Z \leq \frac{b-\mu}{\sigma}\right) = 1 - \Phi\left(\frac{b-\mu}{\sigma}\right)$
- $P(a < X \leq b) = P\left(\frac{a-\mu}{\sigma} < Z \leq \frac{b-\mu}{\sigma}\right) = \Phi\left(\frac{b-\mu}{\sigma}\right) - \Phi\left(\frac{a-\mu}{\sigma}\right)$

## Aditividade das distribuições normais

### Teorema

Se  $x_1, x_2, \dots, x_n$  são v.a. independentes tais que  $x_i \sim N(\mu_i, \sigma_i^2)$   
então a v.a.

$$x = \sum_{i=1}^n a_i x_i \sim N\left(\sum_{i=1}^n a_i \mu_i, \sum_{i=1}^n a_i^2 \sigma_i^2\right)$$

### Corolário

Se  $x_1, x_2, \dots, x_n$  são v.a. independentes com o mesmo valor médio  $\mu$  e a mesma variância  $\sigma^2$  então as v.a. soma e média têm distribuição normal definida por

$$S_n = \sum_{i=1}^n x_i \sim N(n\mu, n\sigma^2)$$

$$\bar{x}_n = \frac{1}{n} \sum_{i=1}^n x_i \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$